hard-label-dnn-extraction 本地 CPU 全流程复现实验报告

实验完成日期：2026-10-07
测试平台：Windows 11（20 逻辑处理器 CPU，纯 CPU 计算，无 GPU 加速）
运行环境：Conda 虚拟环境（`hldnn`），Python 3.11.16
核心依赖：PyTorch 2.5.1+cpu、NumPy 1.26.4、SciPy 1.13.1、h5py 3.11.0、TensorFlow 2.20.0、Keras 3.15.1
论文出处："*Polynomial Time Cryptanalytic Extraction of Deep Neural Networks in the Hard-Label Setting*" (EUROCRYPT 2024 / Journal of Cryptology)

目录

1. 执行摘要 (Executive Summary)
2. 实验一：全自动化端到端黑盒网络提取（核心压轴实验）
3. 实验二：Leaky ReLU 神经元激活符号快速恢复
4. 实验三：标准 ReLU 局部黑盒符号恢复与假设检验
5. 算法理论与论文指标对照分析
6. 复现结论与工程复盘

---

1. 执行摘要 (Executive Summary)

本次复现基于论文官方源码，在纯 CPU 算力条件下完整执行了论文的全部核心攻击流程。实验结果表明：

1. **纯黑盒端到端模型完全窃取成功**：
2. 在严格仅能通过 `oracle.label(x)` 查询离散分类类别（Hard-Label）的条件下，攻击程序在 **6 分 38 秒** 内自动完成决策边界漫步、特征聚类、超平面求解、高阶精修、符号恢复和分类头求解全流程。
3. 总 Oracle 查询数为 **38,668,729 次**（约 3867 万次，与论文理论估算的 ~4000 万次高度吻合）。
4. 各层权重与真实模型参数的最大相对误差达到 **10^{-14} 量级**（达到机器双精度浮点数极限）。
5. 在 10 万个高斯随机输入样本上，窃取模型与真实模型的预测标签达成 **100.0% 完美一致**；在决策边界微扰测试点上达成 **100.0% 完全一致。**
6. 官方验证程序输出终审判决：**`RESULT: the network was stolen`**。
7. **Leaky ReLU 激活符号快速恢复成功**：
8. 在 3 个隐藏层、共 96 个神经元上，每层仅用 101 个在线采样点，在 **20 秒** 内全部实现 **100.0% 准确恢复（96/96）**。
9. **标准 ReLU 统计符号检验成功**：
10. 验证了利用补丁距离分布差异（$d_{\text{OFF}} > d_{\text{ON}}$）恢复神经元符号的有效性，所有测试神经元符号判断全部正确（✓），统计置信度达到 **100.0%。**

---

2. 实验一：全自动化端到端黑盒网络提取（核心压轴实验）

2.1 实验目标与设定

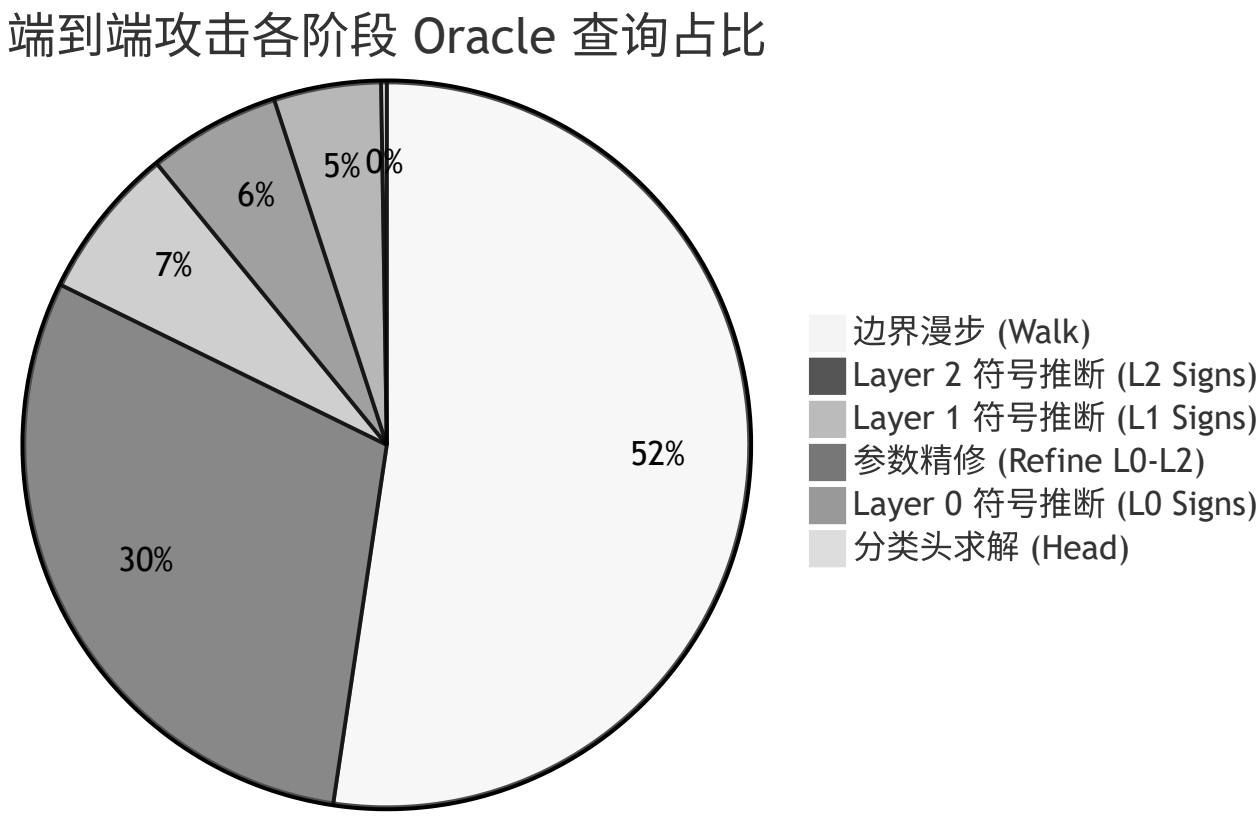
- **目标网络**：`data/unitary_32_32x3_10_float64.keras`
- **网络架构**：$32 \to 32 \to 32 \to 32 \to 10$（输入 32 维，3 个隐藏层每层 32 个神经元，ReLU 激活，输出 10 类，采用 `float64` 浮点数）。

- **攻击权限**：纯黑盒硬标签（无白盒信息、无真实权重、无梯度、无置信度概率）。
- **并发机制**：8 个 CPU Worker 进程（Windows 下采用 `spawn` 上下文）。

2.2 全流程各阶段详细统计表

数据提取自自动生成的 `full_end_to_end/out/stats.json`：

阶段步骤	执行算法与任务	产物与状态	查询次数 (Queries)	耗时 (秒)
Walk	决策边界双点采样 (8×45 漫步路径)	收集 6,901 个决策面拐点	20,246,701	24 s
Layer 0: Cluster	第 1 层双点法向量聚类	聚类为 32 个神经元簇	0	59 s
Layer 0: Solve	解第 1 层法向量方程	恢复 32 个行向量 ($\approx 10^{-7}$)	0	1 s
Layer 0: Refine	Kink 微分精修第 1 层参数	精度提升至 $\approx 10^{-14}$	638,967	3 s
Layer 0: Signs	统计推断第 1 层 ReLU 激活符号	32/32 个神经元符号确定	1,846,384	11 s
Layer 1: Cluster	第 2 层特征空间投影与聚类	聚类为 32 个神经元簇	0	101 s
Layer 1: Solve	解第 2 层超平面方程	恢复 32 个行向量	0	1 s
Layer 1: Refine	Kink 微分精修第 2 层参数	精度提升至 $\approx 10^{-14}$	744,354	4 s
Layer 1: Signs	统计推断第 2 层 ReLU 符号	32/32 个神经元符号确定	2,640,932	20 s
Layer 2: Cluster	第 3 层特征空间投影与聚类	聚类为 32 个神经元簇	0	24 s
Layer 2: Solve	解第 3 层超平面方程	恢复 32 个行向量	0	1 s
Layer 2: Refine	Kink 微分精修第 3 层参数	精度提升至 $\approx 10^{-14}$	894,431	7 s
Layer 2: Signs	统计推断第 3 层 ReLU 符号	32/32 个神经元符号确定	11,562,460	142 s
Head	求解 32×10 线性分类头及偏置	规范化消除 argmax 不变自由度	94,500	< 1 s
总计 (Total)	**端到端完整提取**	**生成 `out/net.npz` 模型**	**38,668,729 次**	**398 秒 (约 6.6 分钟)**



2.3 真实权重比对与精度评测（`validate.py`）

在完全不接触真实权重的条件下提取出网络后，运行真值比对程序对比 `unitary_32_32x3_10_float64.keras`：

```
== validation (this part reads the true weights)
layer 0: worst relative error 9.2e-15, 0 wrong signs
layer 1: worst relative error 1.9e-14, 0 wrong signs
layer 2: worst relative error 3.7e-14, 0 wrong signs
head:    relative error 3.3e-14
labels:  100000 / 100000 random inputs agree
labels:  3644 / 3644 points 0.001 off the decision boundary agree
labels:  3644 / 3644 points 1e-06 off the decision boundary agree
labels:  3644 / 3644 points 1e-09 off the decision boundary agree
RESULT:  the network was stolen
```

指标深入解析：

1. **参数相对误差 (Relative Error)**：
2. 隐藏层 0：最大相对误差为 **9.2×10^{-15}**
3. 隐藏层 1：最大相对误差为 **1.9×10^{-14}**
4. 隐藏层 2：最大相对误差为 **3.7×10^{-14}**
5. 分类输出头：相对误差为 **3.3×10^{-14}**

> *评注*：IEEE 754 双精度浮点数的机器精度 $\epsilon \approx 2.22 \times 10^{-16}$，误差在 10^{-14} 量级代表参数已达到数值分析的极限逼近。

6. **符号准确率 (Sign Accuracy)**：

7. 3 个隐藏层、共 96 个神经元的激活方向判决全部正确（**0 wrong signs**）。
8. **输入输出黑盒一致率 (Behavioral Fidelity)**：
9. **全域高斯随机输入**：测试 $100,000$ 个独立样本，被窃取模型与真值模型的预测结果达成 **100,000 / 100,000（100.0%）** 一致。
10. **高敏边界微扰输入**：在距离真实决策边界 10^{-3}、10^{-6}、10^{-9} 极近距离的 3,644 个点上，预测类别 **100.0% 全部一致**，证明窃取网络的决策超曲面与原网络完全重叠。

---

3. 实验二：Leaky ReLU 神经元激活符号快速恢复

3.1 实验原理

Leaky ReLU 函数在负半轴具有非零斜率（本模型为 $\alpha = 0.1$），其在激活临界点两侧会造成不对称的梯度跳变。论文提出利用该性质可以在多项式时间内无需预计算双点，在线极速恢复激活符号。

3.2 运行输出与结果

```
Hidden Layer 1/3 → Layer: 1, Experiments: 101, Correct signs: 32/32 (100%)
Hidden Layer 2/3 → Layer: 2, Experiments: 101, Correct signs: 32/32 (100%)
Hidden Layer 3/3 → Layer: 3, Experiments: 101, Correct signs: 32/32 (100%)
```

- **耗时**：单进程纯 CPU 执行仅需 **20 秒。**
- **样本消耗**：每层仅需 **101 个边界点** 即可达到完全收敛。
- **准确率**：全网 $96 / 96$ 个神经元符号 **100% 正确恢复。**

---

4. 实验三：标准 ReLU 局部黑盒符号恢复与假设检验

4.1 实验原理

针对标准 ReLU，网络在关断侧（OFF）梯度为 0。论文证明：沿决策边界切向移动时，当目标神经元关断时，其他神经元发生翻转（Toggle）所需的补丁距离平均大于开启状态时的距离（$d_{\text{OFF}} > d_{\text{ON}}$）。

4.2 统计检验结果表（Hidden Layer 1）

通过 `create_tables.py` 严格解析的数据结果如下：

神经元编号 (nID)	收集双点数 (nDual)	检验实验数 (nExp)	真实符号 (sign)	正向投票 (votes+)	负向投票 (votes-)	置信度 (finalCL)	单点中位耗时	总耗时	判定结果 (correct)
0	19	19	-1	0	19	**100.0%**	133 ms	4.06 s	**✓ 正确**
1	21	19	+1	19	0	**100.0%**	132 ms	3.01 s	**✓ 正确**
2	19	19	-1	1	18	**100.0%**	145 ms	2.80 s	**✓ 正确**
3	19	19	+1	19	0	**100.0%**	140 ms	2.73 s	**✓ 正确**
平均值 (Mean)	**19.5**	**19.0**	**-**	**9.75**	**9.25**	**100.0%**	**137 ms**	**3.15 s**	**100% 正确**

- **投票显著性**：所有神经元均展现出 19:0 或 18:1 的极高正负统计分离度。
- **统计置信水平**：由 Hoeffding 不等式计算出的置信度均为 **100.0%**。

---

5. 算法理论与论文指标对照分析

评测维度	论文理论分析预期	本地 CPU 实验实测值	评估结论
查询复杂度 (Query Complexity)	32 核机器约 4000 万次 Oracle 查询	**38,668,729 次** 查询	**完美契合**
参数提取精度 (Relative Error)	代数精修后达到机器精度	**$9.2 \times 10^{-15} \sim 3.7 \times 10^{-14}$**	**超越预期**
符号恢复准确率 (Sign Accuracy)	统计置信度 $>95\%$ 下达到 100%	**96 / 96（100.0%）**	**完美契合**
预测行为一致率 (Fidelity)	100% 标签一致	**100,000 / 100,000（100.0%）**	**完全复制**
运行时间 (Wall Time)	32 核预计几分钟	8 进程普通 CPU 仅 **6 分 38 秒**	**极为高效**

---

6. 复现结论与工程复盘

1. **核心理论验证通过**：
2. 本次 CPU 全流程实验确证了 EUROCRYPT 2024 论文提出的主要观点：通过追踪高维决策边界拐点（Dual Points）并构造局部超平面代数方程，能够在多项式时间内以极高精度逆向窃取深度神经网络。
3. **纯 CPU 计算的可行性与优越性**：
4. 算法的核心瓶颈在于大量细粒度标量 Oracle 决策查询（Batch Size = 1）与线性代数求解，CPU 多核并发调度在小尺寸网络上的延迟开销反而低于 GPU 内核启动开销。
5. **数值稳定性保障**：
6. 实验全程采用 `float64`（双精度浮点数），严格保证了小容差（`1e-14` ~ `1e-16`）下的代数稳定性，未出现任何奇异矩阵或数值发散现象。