Hard-Label 模型窃取：深层提取耗时（16小时）与模型规模（32维 vs 3072维）深度技术剖析

本文档针对 EUROCRYPT 2024 论文 《**Polynomial Time Cryptanalytic Extraction of Deep Neural Networks in the Hard-Label Setting**》 中的两个核心关键疑问进行系统性的理论分析与工程实现解读： 1. **为什么论文中显示第 2 到第 4 层的权重提取耗时长达约 16 个小时？** 2. **为什么复现的端到端完全窃取实验采用的是 32 维小网络？开源项目是否包含了 3072 维 CIFAR-10 的实验？**

目录

1. 核心结论速览
2. 为什么深层（第 2 至 4 层）权重提取耗时长达 16 小时？
3. 2.1 输入维度与神经元数量的断崖式激增（高维计算复杂度）
4. 2.2 深层 ReLU 的层层折叠与掩蔽效应（拐点极度稀疏）
5. 2.3 核心计算瓶颈：对偶空间逆向统一与高维稠密聚类
6. 2.4 级联误差控制与高精度微分精修 (Refinement Optimization)
7. 开源仓库的模型设计定位：Unitary-32 与 CIFAR-10
8. 3.1 开源项目实际上已经内置了 3072 维 CIFAR-10 模型
9. 3.2 为什么端到端全自动窃取 (full_end_to_end) 默认采用 32 维网络？
10. 3.3 庞大中间数据（数十 GB）的外部存储考量
11. 两套模型全维度对比总表
12. 总结与学术复现启示

---

1. 核心结论速览

- **16 小时的来源**：论文中耗时 16 小时的实验针对的是 **CIFAR-10 真实深度网络（$3072 \to 256 \times 3 \to 64 \to 10$）**。耗时极长的主要原因是**深层神经元拐点极度稀疏**，以及在 3072 维高维空间中进行**多层折叠对偶空间的逆向统一（Unifying Dual Spaces）与数十万候选点的成对聚类（Clustering）**，这是高维密码分析的核心算力瓶颈（即使在 256 核 CPU 集群上也需要 16 小时）。
- **开源仓库的模型配置**：开源仓库**确实提供了 3072 维 CIFAR-10 模型**（位于 `data/cifar10_3x256_64_10_float64.keras`）。
- **两类实验的分工定位**：
- `full_end_to_end/` 选用 **32 维网络（`unitary_32`）**：为了将复现门槛从“256核服务器跑整天”降低为“普通 PC 跑 5 分钟”，用极低成本验证零先验、全自动完全窃取闭环的可行性；
- `sign_recovery/` 选用 **3072 维网络（`cifar10`）**：为了实测在大规模真实视觉模型上，高维假设检验与符号判定算法的有效性与收敛速度。

---

2. 为什么深层（第 2 至 4 层）权重提取耗时长达 16 小时？

在极其苛刻的 **Hard-Label（硬标签，仅能获取 Top-1 离散类别输出）** 纯黑盒设定下，攻击者无法获取任何内部激活值或损失梯度，只能依靠在最终决策边界上观察超平面的“折痕拐点”（Dual Points / Kinks）。

提取深层权重之所以需要 16 小时，是由以下四大数学与计算瓶颈决定的：

2.1 输入维度与神经元数量的断崖式激增（高维计算复杂度）

- **小网络对比**：32 维网络中，每个神经元的法向量只有 32 维，全网共 96 个神经元；
- **CIFAR-10 网络**：输入图像是 $32 \times 32 \times 3 = 3072$ 维，隐藏层宽度为 256（共 $256 \times 3 + 64 = 832$ 个神经元）。
- 寻找超平面、求解线性齐次方程组、奇异值分解（SVD）和正交投影矩阵计算的算法复杂度与维度 d 呈高阶多项式关系（$O(d^3)$ 级别）；
- 当向量维度从 32 激增至 3072（扩大近 100 倍）时，底层的单次高精度矩阵浮点运算量暴增了数万倍。

2.2 深层 ReLU 的层层折叠与掩蔽效应（拐点极度稀疏）

- **第 1 层神经元**：直接暴露在外部输入空间中，其超平面 $w_1 x + b_1 = 0$ 是平直的，决策边界漫步极其容易碰撞并收集到有效拐点；
- **第 2 至 4 层神经元（深层隐藏层）**：
- 深层神经元被前方所有层的 ReLU 激活函数层层折叠；
- 若前序神经元处于未激活状态（输出为 0），后层神经元的输入信号就被**完全截断**；
- **深层神经元的折痕（Kink）必须在前面所有相关神经元同时处于激活状态（Active Pattern）时，才能在最外层的最终分类决策边界上被"投影"并被外部观察到**；
- 随着层数加深，可见拐点在输入空间中的出现概率呈**指数级衰减。**为了采集到足以覆盖第 2~4 层所有 256 个神经元的拐点集合，必须发起数以亿计的漫步与二分高精度逼近。

2.3 核心计算瓶颈：对偶空间逆向统一与高维稠密聚类

这是论文明确指出**耗时最长（占绝大部分时间）的致命计算瓶颈**： 1. **多面体碎片化（Piecewise Linear Facets）**： 一个深层神经元的临界超平面，在穿透前序层划分出的数千个不同线性区域（Polyhedral Cells）时，在输入空间呈现为成千上万个离散碎裂的分段小平面； 2. **对偶空间逆向展开（Unifying Dual Spaces）**： 算法必须依据已求解出的前层权重矩阵，将这数十万个高维双点碎片，逐一做逆向仿射变换映射回第 L 层的隐藏特征空间； 3. **高维成对聚类（Clustering Bottleneck）**： 在海量的高维候选点集合中，必须计算所有候选点对之间的夹角与投影相似度（Cosine Distance），将同一神经元的碎点聚为一类。 聚类复杂度为 $O(N^2 \cdot d)$，当 N 达到数十万且 $d=3072$ 时，运算量达到惊人的**千万亿次浮点矩阵乘法。**论文作者在拥有 **256 个 CPU 核心的超级服务器集群** 上全负荷并行运算，仅聚类阶段就持续了 **约 16 个小时。**

2.4 级联误差控制与高精度微分精修 (Refinement Optimization)

- 深度神经网络的逐层窃取属于**级联依赖型算法**：第 2 层依赖第 1 层的解，第 3 层依赖前两层的解。
- 浮点舍入与逼近误差会随着层数加深被**逐层指数放大。**
- 为防止第 3、4 层因累积误差而全盘崩溃，论文在第 2~4 层中对每个聚类出的超平面引入了极其严苛的 **Kink 微分精修算法。**该算法需要在微小邻域内反复沿法向量两侧微扰并调用 Oracle 查询，单神经元的精修耗时成倍增加。

---

3. 开源仓库的模型设计定位：Unitary-32 与 CIFAR-10

3.1 开源项目实际上已经内置了 3072 维 CIFAR-10 模型

在仓库根目录的 `data/` 目录下，包含以下文件： * `cifar10_3x256_64_10_float64.keras`（大小约 7.5 MB，标准 CIFAR-10 训练得到的 $3072 \to 256 \times 3 \to 64 \to 10$ 真实模型）。 * `sign_recovery/sign_recovery_whitebox.py` 与 `dual_generator_whitebox.py` 均默认以该模型为操作目标。 * **我们已完成的实测**：在 RTX 4090 服务器上运行的实验三，就是针对此 CIFAR-10 模型进行的第一层 16 个神经元符号恢复评测。

3.2 为什么端到端全自动窃取 (full_end_to_end) 默认采用 32 维网络?

作者在 `full_end_to_end/README.md` 中说明了其初衷： 1. **可复现性与学术共享门槛**： 大部分研究者、审稿人或学生并不具备持续租用 256 核云服务器跑数十小时的条件。如果端到端入口直接绑定 CIFAR-10，普通复现者跑几天都无法得到结果，且极易因单机内存不足（OOM）而中途崩溃； 2. **数学原理完全等价**： `unitary_32` 是一个严格构造的 3 隐藏层非线性神经网络，它完整涵盖了端到端攻击的每一个环节（漫步采集 $\to$ 聚类 $\to$ 恢复行向量 $\to$ 微分精修 $\to$ 符号恢复 $\to$ 输出头重构）。 在 32 维模型上跑出 10^{-14} 的机器精度极限并输出 `THE NETWORK WAS STOLEN!`，在理论上完全足以证明算法闭环的正确性。

3.3 庞大中间数据（数十 GB）的外部存储考量

- 在 3072 维下，恢复全部 832 个神经元需要数十万个双点三元组（Triplet Points），原始采样数据体积达 **数十 GB。**
- 受限于 GitHub 单仓库 1GB/单文件 100MB 的上传限制，作者无法将 CIFAR-10 完整的预计算双点数据直接打包进代码库，而是：
- 将庞大数据集拆分并托管在专用的外部仓库： `precomputation-for-hard-label-dnn-extraction`；
- 提供了在线/白盒双点生成脚本 `generators/dual_generator_whitebox.py` 供有算力的研究者自行生成。

---

4. 两套模型全维度对比总表

对比维度	端到端验证网络（`unitary_32`）	真实视觉深度网络（`cifar10`）
应用模块	`full_end_to_end/`（端到端一键完全窃取）	`sign_recovery/`（高维符号恢复与白盒验证）
输入维度 d	**32 维**	**3072 维**（高出近 100 倍）
网络隐藏层架构	$32 \to 32 \to 32$（共 96 个神经元）	$256 \to 256 \to 256 \to 64$（共 832 个神经元）
全精度数据类型	IEEE 754 `float64` 双精度浮点	IEEE 754 `float64` 双精度浮点
端到端 Oracle 查询量	约 3900 万次	预估数亿至数十亿次
深层提取计算耗时	**约 5~6 分钟**（本地 8 进程 / 服务器 32 核）	**约 16 小时（256 核心服务器集群）**
后续符号恢复耗时	约 1~2 分钟	约 8.5 小时
生成中间数据体积	几兆字节（`out/` 约 6 MB）	数十吉字节（数十 GB 预计算点集）
攻击最终结果判定	100% 恢复，相对误差 $< 10^{-14}$，输出 Stolen	抽样神经元 95% 置信度提早收敛，速度比显著
在论文中的核心定位	**端到端纯黑盒闭环可行性验证**	**真实数据集与高维抗性压力测试**

---

5. 总结与学术复现启示

1. **论文的完整性**：论文并非只提出了理论，作者不仅在 256 核集群上完成了 16 小时的 CIFAR-10 极限制表，也把 CIFAR-10 模型本身开源到了 `data/` 目录中。
2. **复现的合理性**：
3. 我们在复现中采用 `unitary_32` 验证 **端到端全自动完全窃取闭环**，用几分钟的极高效率取得了 100,000/100,000 决策一致性与 10^{-14} 相对误差的完美收敛，证明了算法逻辑的无懈可击；
4. 与此同时，我们在服务器端运行了 **CIFAR-10 (3072 维) 的真实神经元符号恢复实验**，复现并验证了高维视觉模型下的位移速度比与假设检验有效性。
5. 两者互为补充，构成了对这篇 EUROCRYPT 顶会论文最完整、最具工程可操作性的复现闭环。